智能视觉感知软件的对抗鲁棒性测试与自动化评估

方向 8 -小组 1 开题报告

一、研究意义

深度神经网络在图像分类任务中展现出卓越性能，但普遍存在**高精度、高脆弱**的核心悖论。在自动驾驶场景中，微小的对抗扰动即可使系统将“停车让行”标志误判为“限速”标志，引发重大交通安全事故；在人脸识别领域，攻击者可通过简易手段伪造身份信息，造成个人隐私泄露与信息安全威胁；在智能收银场景中，对抗贴纸类攻击会直接导致商家经济损失。因此，深入研究视觉模型的对抗鲁棒性，构建高效的攻击防御机制，对保障智能视觉系统的安全稳定应用具有重要的现实意义与工程价值。

二、相关现状调研

对抗样本是指在原始正常图像中添加人眼不可感知的微小噪声，即可导致深度学习模型产生错误识别结果的特殊样本。该领域的奠基性研究为 Goodfellow 团队在 ICLR 2015 提出的 FGSM 快速梯度符号攻击[2]：通过计算损失函数对输入数据 x 的梯度，提取梯度符号方向 $sign$，乘以微小扰动系数 ε 后叠加至原图，可轻松欺骗模型。该研究颠覆了传统认知，证明神经网络易受对抗攻击的本质是高维空间中的线性特性，为对抗样本的生成机理研究奠定了理论基础。

模型**鲁棒性评估**的核心手段源自 Madry 团队在 ICLR 2018 提出的 PGD 投影梯度下降攻击[3]，该方法为迭代式增强攻击算法，通过多次迭代优化扰动并将其约束在合法范围内，能够突破常规防御机制，是深度学习模型对抗鲁棒性评估的标准基准方法。本研究将以 PGD 攻击下的模型准确率作为核心评估指标。

虽然 PGD 攻击奠定了迭代攻击的基础，但单一攻击手段往往因**超参数敏感**或模型存在的**梯度掩盖**现象导致鲁棒性被高估。为此，Croce 团队在 NeurIPS 2020 提出了 RobustBench 标准化基准[4]：该工作引入了集成攻击工具 AutoAttack[5]，通过组合多种白盒与黑盒攻击，如 FAB 和 Square Attack；有效避免了手动调参的过程，为模型安全性提供了真值评估标准。本研究将参考此标准化理念，构建**自动化评估**流水线。

在**基础模型**层面，选用何恺明团队于 CVPR 2016 提出的 ResNet 残差网络[1]，该网络是图像分类领域的经典基准模型。其核心创新为引入残差连接结构，通过捷径支路实现跨层信息传递，有效解决了深层神经网络训练中的梯度消失问题；支持网络稳定搭建至上百层结构，兼顾了模型深度与分类性能，是工业界与学术界广泛使用的 backbone 网络。

三、所选择工具初步搭建情况

（一）基础模型选型

基于前期调研，本研究选取**基于 ResNet-18 架构的果蔬识别系统**作为实验载体，该项目为 GitHub 开源项目，具备完善的功能与工程化实现：

1. 支持 36 类日常果蔬（苹果、香蕉、生姜等）的多类别图像分类；
2. 集成完整的训练循环、验证逻辑，搭载 TensorBoard 可视化监控模块，支持模型权重保存、加载与断点续训，可输出预测类别与置信度；
3. 应用场景广泛，覆盖农业自动化分拣、移动端饮食管理 App、超市自助收银机等实际落地系统。

选择该项目的核心优势：

1. **可行性高**：代码架构清晰，采用 argparse 进行参数管理，基于成熟的 timm 模型库开发，模块化设计便于嵌入 PGD 攻击代码；ResNet-18 为轻量化模型，计算开销低，可在笔记本电脑上快速生成对抗样本、迭代实验。
2. **代表性强**：ResNet 为工业级识别系统的通用基准网络，研究结论具备普适性；果蔬识别任务包含光照变化、目标遮挡等自然扰动，是典型的视觉感知任务，适配鲁棒性测试需求。
3. **实用价值突出**：该系统在实际应用中存在安全与经济风险，针对其开展鲁棒性研究具备实际应用意义。

（二）对抗攻击工具

选用 **TorchAttacks** 作为核心攻击库，该工具轻量化、易集成，封装了 FGSM、PGD、CW 等主流对抗攻击算法，无需繁琐的公式推导即可直接调用复现，大幅提升开发与实验效率。

（三）开发环境与工具链

采用 TorchVision 完成图像预处理与数据集加载，复用原项目逻辑保证对抗样本有效性；通过 NumPy 实现鲁棒性核心指标的量化统计，结合 Matplotlib 完成实验结果可视化绘图。目前小组已完成 PyTorch、TorchAttacks 、TorchVision、NumPy、Matplotlib 等依赖库的安装与环境配置。

四、进度安排与预期成效

（一）研究进度安排

时 间	阶 段	核 心 工 作
第 1 周	环境搭建与基准测试	完成开发环境配置，跑通开源果蔬识别项目，统计模型在清洁样本上的基准准确率。
第 2 周	对抗攻击复现	复现 FGSM、PGD 对抗攻击算法，生成对抗样本，测试模型在攻击下的性能衰减规律。
第 3 周	自动化评估框架构建	开发批量测试脚本，实现不同攻击参数下鲁棒性指标的自动统计与可视化输出。
第 4 周	鲁棒性改进与验证	实施输入预处理、对抗训练等防御策略，对比分析模型优化前后的鲁棒性差异。
第 5 周	总结与成果整理	分析实验数据，完善项目仓库，完成研究报告的撰写与成果梳理。

（二）预期成效

改进方向：

1. 构建鲁棒性自动化评估框架（测试侧）

参考 RobustBench 的标准化评估理念，在原有的 evaluate 函数基础上，新增 adversarial_evaluate 模块：开发**自动化评估脚本**，在 $L\infty$ 范数约束下，自动遍历 ε 在 0 ~ 0.1 区间内的不同扰动强度；框架将自动汇总实验数据，生成标准化的

模型质量报告，包含**模型衰减曲线**（展示模型准确率随扰动强度增加的下降速度）和**类别混淆热力图**（定量分析易混淆的果蔬类别）。

2. 引入对抗训练机制（防御侧）

优化原有仅使用原始图像的训练流程，在训练循环中实时生成 **PGD 对抗样本**，混合至训练集完成模型训练；并进行**防御 Trade-off 评估**，对比清洁准确率与对抗准确率，分析引入防御机制所带来的计算开销与精度损失。

预期成果：

1. 自动化评估框架：支持批量对抗样本生成、核心指标自动计算、可视化报告输出，显著提升模型测试效率。
2. 有效的防御策略：验证对抗训练这一鲁棒性提升方案，实现模型对抗准确率的有效优化。
3. 形成涵盖理论研究、实验验证、方案优化的系统性研究报告。

五、参考文献

[1] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[2] Goodfellow I J, Shlens J, Szegedy C. Explaining and Harnessing Adversarial Examples[J]. arXiv preprint arXiv:1412.6572, 2015.

[3] Madry A, Makelov A, Schmidt L, et al. Towards Deep Learning Models Resistant to Adversarial Attacks[J]. arXiv preprint arXiv:1706.06083, 2018.

[4] Croce F, Andriushchenko M, Sehwag V, et al. RobustBench: a standardized adversarial robustness benchmark[C]//Advances in Neural Information Processing Systems. 2020, 33: 19866-19881.

[5] Croce F, Hein M. Reliable Evaluation of Adversarial Robustness with an Ensemble of Diverse Parameter-free Attacks[C]//Proceedings of the International Conference on Machine Learning. 2020: 2206-2216.