西安电子科技大学计算机科学与技术学院

软件质量保障开题报告

学生姓名 王薇 王璟 肖洋 冯子诚 孙宏鑫

专　　业 软件工程

学　　号 23009200489 23009201156

23009200031 23009200084

23009200453

指导教师 于斌

2026 年　4　月 1　日

（本表一式三份，学生、指导教师、学院各一份）

一、项目名称

基于 LSTM 的时序预测对抗攻击与鲁棒性分析

二、研究目的和意义

研究目的：

近年来，深度学习模型，尤其是长短期记忆网络（LSTM）、双向长短期记忆网络（BiLSTM）以及门控循环单元（GRU）等，在处理多元时间序列（Multivariate Time Series, MTS）回归预测任务中展现出了卓越的性能。这些技术已被广泛应用于金融市场预测[1][2]、智能电网负荷监测[3][4]、气象预报以及工业设备剩余寿命预估等诸多领域。然而，深度学习模型往往容易受到对抗样本（Adversarial Examples）的欺骗。 目前，对抗攻击的研究大多集中在计算机视觉的图像识别领域，而针对多元时间序列回归预测模型的安全性评估却极度匮乏。本课题旨在填补这一空白，不仅复现传统的全局对抗攻击（如快速梯度符号法 FGSM、基本迭代法 BIM），更针对时序数据的独有特性，提出并实现一种面向时序预测模型的关键时间步微扰攻击框架（KTSA, Key Time-Step Attack）。课题将通过计算梯度显著性，在更小的有效扰动范围（如 Top 10% 的关键时间步）内实施精准打击，并进一步探索基于对抗训练的模型鲁棒性增强方案。

研究意义：

现实价值： 在现实中，智能电网或金融系统等属于“成本与安全高度敏感”的关键应用。如果攻击者通过虚假数据注入技术（False Data Injection）对传感器采样点施加人眼难以察觉的微小扰动，可能导致模型预测出现严重偏差（如预测电网负荷暴增或突降），进而引发全国性停电或巨大的经济损失。KTSA 框架由于只攻击少部分关键时间步，更符合现实中黑客难以篡改全周期数据、只能局部篡改的真实场景。因此，提前揭示此类模型的脆弱性并探索防御机制，具有极强的现实防卫意义。

学术价值： 传统的对抗攻击通常对整个序列的每个时间步均匀施加扰动。本课题充分利用了时间序列数据“关键片段贡献不均衡”的结构特点（即某些时间步承载了更多的趋势转折或动态变化信息）。将攻击策略从传统的“全局均匀扰动”推向“时间维稀疏选择性精准微扰”，填补了针对长依赖时序模型定向隐蔽攻击的理论探索空间，为后续时序安全领域的研究提供了新的评估维度和改进思路。

三、国内外研究现状和发展趋势

时序对抗攻击的起步与现状： 在图像处理中，对抗样本通过对像素添加微小扰动来欺骗模型；而在时序领域，攻击直接作用于连续的传感器数据流。最新的核心研究文献（如 G. R. Mode 和 K. A. Hoque[错误!未找到引用源。]）首次系统性地将 FGSM 和 BIM 等经典攻击方法引入多元时间序列回归任务中，并在 LSTM、GRU 和 CNN 三种主流架构上验证了其高破坏性以及在黑盒条件下的可迁移性。

现有白盒攻击的痛点与局限性： 虽然 FGSM 和 BIM 在时序回归任务中被证明有效，但它们本质上属于全时域均匀攻击，即对整个时间序列的所有时间步统一施加最大容忍度（ϵ）内的扰动。这种全局扰动方式数据修改量过大，不仅没有利用时序模型的注意力偏好，而且在实际物理部署中，大面积的数据异常极易被现有的工业异常检测系统拦截，缺乏足够的隐蔽性与针对性。

技术发展趋势与本课题的切入点： 针对时序数据的对抗攻击，未来的策略必然向着更加稀疏、隐蔽和具有高度解释性的方向演进。本课题提出的 KTSA 框架正是顺应了这一趋势，通过结合基于梯度的显著性图（Saliency Map），量化各时间步的贡献度函数 S(t)，并构造时间掩码矩阵（Mask Matrix），将扰动精准锁定在得分最高的 Top K 个时间步上。此外，从单纯的“揭示脆弱性”走向“构建防御护城河”（如引入对抗样本混合训练以降低 RMSE 波动），也是当前深度学习安全领域的必然趋势。

四、初步搭建情况

本课题的软硬件环境配置与基线工程初步搭建已取得实质性进展，具备了坚实的工程开发基础：

基础环境与工程底座搭建：选用 PyTorch 深度学习框架作为核心开发工具，并以 GitHub 优秀的开源项目 dependable-cps/adversarial-MTSR 为底层架构开展复现与定制化开发。该项目原生支持 LSTM 架构，数据预处理与模型评估逻辑解耦良好，为我们后续注入“关键时间步掩码（Mask）”预留了清晰的接口。

基线模型与数据集特性验证： 团队已成功跑通了原始 LSTM 时序预测的实验基线，并接入了标准的 FGSM 单步攻击与 BIM 迭代攻击。在对开源的家用电力数据集（Power）和交通数据集（Traffic）进行评估时，我们获得了关键发现：Power 数据集处理后的输入窗口仅为 1 个时间步（7 个特征），导致 KTSA 的“前 10% 时间步筛选”会退化为全局攻击；而 Traffic 数据集的输入窗口长度为 12 个时间步，完美支持 KTSA 的时间步筛选逻辑。因此，后续核心验证实验将全面聚焦于 Traffic 数据集。

核心改进算法（KTSA）的初步实现： 目前，团队已成功编写并实现了

KTSA-FGSM 和 KTSA-BIM 算法。代码能够通过反向传播获取输入序列的梯度计算显著性得分，并提取 Top 10% 的关键时间步生成布尔掩码矩阵，确保扰动仅在关键位置生效，初步实现了“稀疏、时序选择性攻击”的逻辑闭环。

量化评估流程构建： 自动化测试脚本已经完善，可一键输出 Clean（干净样本）、FGSM、BIM、KTSA-FGSM、KTSA-BIM 五种场景的对比结果。评估指标严格采用了均方根误差（RMSE）和平均绝对误差（MAE），并额外输出了扰动比例（Top ratio）与相对误差增量，为后续更深入的实验提供了量化支撑。

五、进度安排与预期成效

第一阶段：核心算法实现与基线打通（4.5 — 4.12）

工作内容：完善 PyTorch 深度学习环境配置，跑通电力（Power）与交通（Traffic）数据集上的多元时序回归基线，复现标准 FGSM 与 BIM 全局攻击。构建量化评估流程（集成 RMSE 和 MAE 指标），并重点完成核心改进算法 KTSA 的代码实现，验证基于梯度显著性筛选 Top 10% 关键时间步生成掩码（Mask）的可行性。

预期成效：实现“稀疏、时序选择性攻击”的逻辑闭环，输出初步的五组对比结果（Clean, FGSM, BIM, KTSA-FGSM, KTSA-BIM）。

第二阶段：对照实验与超参数扫描验证（4.13 — 4.20）

工作内容：在具备 12 个时间步窗口的 Traffic 数据集上深入开展量化实验。引入 Random-Step-FGSM 和 Random-Step-BIM 作为随机选步对照组进行控制变量测试。同时，开展关键时间步比例（Top ratio: 5%, 10%, 20%, 30%, 50%）的扫描实验。

预期成效：通过严谨的数据证明 KTSA 的优势来源于“关键时间步的科学选择”，并绘制性能变化趋势折线图，寻找“攻击隐蔽性”与“预测破坏强度”的最佳平衡点。

第三阶段：模型架构拓展与有效性验证（4.21 — 4.28）

工作内容：在现有 LSTM 代码基础上，新增 BiLSTM（双向长短期记忆网络）模型分支。分别编写并调试 Traffic_BiLSTM.py 等测试脚本，验证 KTSA 框架在双向时序特征提取下的普适性与泛化能力。

预期成效：获得一个更适合验证“关键时间步选择”的增强模型分支，确认本课题提出的攻击方法对不同循环神经网络架构的通用性。

第四阶段：数据可视化、鲁棒性防御与论文定稿（4.29 — 5.7）

工作内容：整理 KTSA 方法定义、关键公式以及所有的实验图表数据。输出关键时间步梯度的显著性分布可视化热图（Saliency Map）。视进度情况，探索在训

练中加入对抗样本混合训练以增强模型鲁棒性的防御方案。

预期成效：将实验结论转化为一套可直接用于答辩或课程报告的图表与方法说明，完成毕业设计论文的撰写、格式修改与定稿，并做好最终的答辩准备。

六、参考文献

[1] Cao J, Li Z, Li J. Financial time series forecasting model based on CEEMDAN and LSTM[J]. Physica A: Statistical mechanics and its applications, 2019, 519: 127-139.

[2] Ferdiansyah F, Othman S H, Radzi R Z R M, et al. A lstm-method for bitcoin price prediction: A case study yahoo finance stock market[C]//2019 international conference on electrical engineering and computer science (ICECOS). IEEE, 2019: 206-210.

[3] Wen S, Wang Y, Tang Y, et al. Real-time identification of power fluctuations based on LSTM recurrent neural network: A case study on Singapore power system[J]. IEEE Transactions on Industrial Informatics, 2019, 15(9): 5266-5275.

[4] Li K, Huang W, Hu G, et al. Ultra-short term power load forecasting based on CEEMDAN-SE and LSTM neural network[J]. Energy and Buildings, 2023, 279: 112666.

[5] Mode G R, Hoque K A. Adversarial examples in deep learning for multivariate time series regression[C]//2020 ieee applied imagery pattern recognition workshop (aipr). IEEE, 2020: 1-10.