ReLU 神经网络鲁棒性验证开题报告

一、研究意义

随着深度学习技术在自动驾驶、医疗诊断、卫星故障检测等安全关键系统中的广泛应用，神经网络的可靠性和安全性问题日益突出。ReLU（Rectified Linear Unit）作为目前最常用的激活函数之一，虽然具有计算高效、缓解梯度消失等优点，但其对输入扰动极为敏感。研究表明，对原始图像施加人眼难以察觉的微小扰动（即对抗样本），就可能导致神经网络输出完全错误的预测结果，从而引发灾难性事故。因此，如何从形式化验证的角度保证 ReLU 神经网络在给定输入范围内的鲁棒性，即对于所有合法扰动，网络的预测结果保持一致，成为当前人工智能安全领域亟待解决的核心技术问题。

本课题聚焦于 ReLU 激活函数的全连接神经网络，调研并对比现有的主流鲁棒性验证工具，重点选用具有高性能和 GPU 加速能力的 α,β-CROWN 工具，开展验证实验。通过构建不同深度（2 层、4 层、6 层）的 MNIST 分类网络，测量其在常见扰动半径（ε=0.02, 0.05）下的验证精度和时间开销，探索基于关键层或关键神经元的简化验证策略。研究成果一方面可为安全关键系统中神经网络的可信部署提供验证方法支持，另一方面可为后续改进验证算法的效率和可扩展性提供实验基础和思路启发。

二、相关现状调研

（一）神经网络鲁棒性验证的主要技术路线

当前主流的神经网络鲁棒性验证方法可以分为精确验证方法和近似验证方法两大类。精确验证方法通常将验证问题转化为可满足性模理论（SMT）或混合整数线性规划（MILP）问题，通过求解器寻找反例。这类方法理论上可以给出确定的“安全”或“不安全”结论，但计算复杂度随网络规模指数增长，难以处理超过数百个神经元的网络。近似验证方法则采用边界传播、区间分析、抽象解释等技术，以损失部分完备性（可能将安全样本误判为不安全）为代价，获得更高的验证效率。近年来，基于线性松弛和边界传播的方法（如 CROWN 系列）结合 GPU 并行计算，在验证规模和速度上取得了显著突破。

（二）代表性验证工具对比

根据相关文献的最新结果，当前具有代表性的工具包括：

1. Marabou：基于 SMT 求解的精确验证工具，支持交互式分析和部分非线性激活函数。2024 年发布的 2.0 版本预处理速度提升了 60 倍。Marabou 已被成功应用于卫星故障检测等实际安全关键系统，但受限于网络规模，验证深层网络时仍面临性能瓶颈。

2. α,β-CROWN：基于边界传播和线性松弛的近似验证工具，支持 GPU 加速。能够高效验证具有数千个神经元的网络，是目前可扩展性最优的验证工具之一。

3. VeriNet：专注于符号传播优化，通过分层抽象和动态边界调整提升验证效率。

上述工具在方法论上各有侧重：Marabou 代表精确但代价较高的求解路线，α,β-CROWN 代表可扩展的近似边界传播路线。两者具有天然的互补性——精确工具可用于小规模网络的确定性验证，近似工具可用于大规模网络的快速筛选。本课题将在参考论文实验设计的基础上，系统对比这些工具的适用边界，并最终选择α,β-CROWN 作为主要实验平台，探索改进策略。

三、所选工具初步搭建情况

（一）工具安装与环境配置

本研究选择α,β-CROWN 作为核心验证工具，主要理由如下：（1）竞赛验证：连续两年获得 VNN-COMP 冠军，算法性能和工程实现均处于顶尖水平；（2）GPU 加速：支持 CUDA 并行计算，能够处理比 CPU 工具更大规模的网络；（3）实验对齐：参考论文已将α,β-CROWN 作为基准工具之一，实验结果可直接对比；（4）易于上手：提供完整的 Python 接口和训练脚本。

实验环境为 Windows 操作系统，通过 conda 创建独立 Python 环境，并按照官方文档完成α,β-CROWN 的安装。依赖库包括 PyTorch、NumPy、tqdm 等，均已成功配置。

（二）目标网络训练

参考论文的实验设置，本研究训练了三个不同深度的全连接 ReLU 网络，均基于 MNIST 手写数字数据集（输入为 28×28 像素，输出为 10 类）。隐藏层大小统一设为 256 个神经元，网络深度分别为 2 层、4 层和 6 层。训练采用交叉熵

损失函数和 Adam 优化器，每个网络训练 10 个轮次。训练过程截图显示：

```
(abcrown) E:\XDstudy\ARVerifier\alpha-beta-CROWN-main>python train_mnis
t_fc.py
100%|██████████████████████████| 9.91M/9.91M [07:33<00:00, 21.9kB/s]
100%|██████████████████████████| 28.9k/28.9k [00:00<00:00, 53.4kB/s]
100%|██████████████████████████| 1.65M/1.65M [00:41<00:00, 39.3kB/s]
100%|└└└
```

（三）鲁棒性验证实验

针对每个训练好的网络，选取 MNIST 测试集中的前 25 个样本（共 75 个样本，但因三个网络使用相同样本顺序，实际总计验证 150 次，因为每个样本两个 ε），分别设置扰动半径 ε=0.02 和 ε=0.05（L∞范数）。使用 α,β-CROWN 自带的批量验证脚本（batch_verify.py）执行鲁棒性验证。验证过程截图显示：150 个验证任务在约 13 分 53 秒内完成，平均每个样本耗时约 5.56 秒。

```
(abcrown) E:\XDstudy\ARVerifier\alpha-beta-CROWN-main>
(abcrown) E:\XDstudy\ARVerifier\alpha-beta-CROWN-main>python batch_verify.py
验证进度: 100%|██████████████████████| 150/150 [13:53<00:00,  5.56s/it]

所有验证完成！结果已保存至 my_experiments/verification_results.csv
```

verification_results.csv - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
model,epsilon,index,true_label,result,time_seconds
fc2,0.02,0,7,unknown,5.505441427230835
fc2,0.02,1,2,unknown,5.051065683364868
fc2,0.02,2,1,unknown,4.752969980239868
fc2,0.02,3,0,unknown,4.700328588485718
fc2,0.02,4,4,unknown,4.812346696853638
fc2,0.02,5,1,unknown,4.873468399047852
fc2,0.02,6,4,unknown,4.7491233348846436
fc2,0.02,7,9,unknown,4.880347490310669
fc2,0.02,8,5,unknown,4.764937400817871
fc2,0.02,9,9,unknown,4.740756034851074
fc2,0.02,10,0,unknown,4.815671920776367
fc2,0.02,11,6,unknown,4.754021167755127
fc2,0.02,12,9,unknown,4.7605860233306885
fc2,0.02,13,0,unknown,4.886850357055664
fc2,0.02,14,1,unknown,4.745645999908447
fc2,0.02,15,5,unknown,4.780972003936768
fc2,0.02,16,9,unknown,4.8574299812316895
fc2,0.02,17,7,unknown,4.809483766555786
fc2,0.02,18,3,unknown,4.874491930007935
fc2,0.02,19,4,unknown,4.9902729988098145
fc2,0.02,20,9,unknown,4.778698921203613
fc2,0.02,21,6,unknown,4.809659957885742
fc2,0.02,22,6,unknown,4.7757158279418945
fc2,0.02,23,5,unknown,4.786875009536743
fc2,0.02,24,4,unknown,4.834385633468628
fc2,0.05,0,7,unknown,4.890737533569336
fc2,0.05,1,2,unknown,5.04282283782959
fc2,0.05,2,1,unknown,4.849095106124878
fc2,0.05,3,0,unknown,4.872657299041748
fc2,0.05,4,4,unknown,4.972778797149658
fc2,0.05,5,1,unknown,4.896080255508423
fc2,0.05,6,4,unknown,4.91219687461853
```

第 4 行，第 39 列 100% Windows (CRLF) UTF-8

验证结果保存在 my_experiments/verification_results.csv 中，部分记录如下：fc2 网络、ε=0.02、索引 0 的样本结果为“unknown”，耗时 5.505 秒；后续样本类似。随后使用 analyze_results.py 脚本对结果进行统计分析，输出汇总表如下：

model	epsilon	safe_count	unknown_count	timeout_count	avg_time(秒)
fc2	0.02	25	0	0	4.8437
fc2	0.05	25	0	0	4.9768
fc4	0.02	25	0	0	6.7468
fc4	0.05	25	0	0	6.2551
fc6	0.02	25	0	0	5.2920
fc6	0.05	25	0	0	5.2188

从初步结果可以看出：（1）所有 150 个验证任务均未超时，工具运行稳定；（2）对于当前选择的样本和扰动半径，α,β-CROWN 给出的验证结果均为“安全”（safe_count=25，即每个配置下的 25 个样本全部通过鲁棒性验证）；（3）验证时间随网络深度增加而略有增长，但 6 层网络反而略低于 4 层，可能与具体样本的验证难度波动有关。

以上结果表明α,β-CROWN 能够有效完成中等规模 ReLU 网络的鲁棒性验证，为后续改进实验奠定了数据基础。

四、进度安排与预期成效

（一）进度安排

根据当前已完成的工作和后续研究目标，制定如下进度计划：

1. 第 1-4 周（已完成）：文献调研与工具选型。阅读 IJCAI 2025 等相关论文，对比 Marabou、α,β-CROWN 等工具，确定以α,β-CROWN 为主要平台；完成环境搭建和 MNIST 网络训练，初步跑通验证流程。

2. 第 5-7 周：系统对比实验。扩展验证样本数量(例如每个网络验证 100-200 个样本），记录不同深度（2,4,6 层）和不同扰动半径（0.02,0.05,0.1）下的验证成功率与时间开销；同时尝试安装 Marabou 工具，在小规模网络上进行对比验证，量化精确方法与近似方法的性能差异。

3. 第 8-11 周：改进策略设计与实现。基于参考论文中的“抽象加速”思想，设计关键层/关键神经元筛选方法。具体思路：通过敏感性分析（如计算每层输

出对输入扰动的 Lipschitz 常数）或神经元活跃度统计（在训练集上统计每个 ReLU 单元的激活频率），识别出对整体鲁棒性影响最大的前 k 个神经元或若干关键层。然后修改 α, β -CROWN 的验证流程，使其仅对这些关键部分进行紧致边界传播，其余部分采用宽松近似。以牺牲极小部分完备性为代价，预期将验证速度提升 30%-50%。

4. 第 12-15 周：实验评估与论文撰写。在相同数据集和网络结构下，对比原始 α, β -CROWN 与改进后版本的验证时间、安全判定一致性；整理实验结果，分析改进策略的有效性和局限性；撰写结题报告或小论文。

（二）预期成效

1. 完成对 2 层、4 层、6 层 ReLU 网络在 MNIST 数据集上的鲁棒性验证基准测试，获得不同深度和扰动半径下的验证性能数据。

2. 初步实现一种基于关键神经元筛选的简化验证方法，能够在保持较高安全判定准确率的前提下，明显缩短验证时间（预计提速 30%以上）。

3. 形成一份完整的开题报告和结题报告，清晰总结 ReLU 神经网络鲁棒性验证的研究现状、工具对比及改进思路。

4. 所积累的实验脚本和验证结果可为课题组后续研究提供可复用的基础。

五、参考文献

[1] Liu, Y., Dong, Y., Zhao, L., Wang, W., & Tian, C. (2025). Neuron Similarity-Based Neural Network Verification via Abstraction and Refinement. IJCAI 2025.

[2] Katz, G.,et al. (2019). The Marabou framework for verification and analysis of deep neural networks. CAV 2019.

[3] Zhang, H, et al. (2022). General Cutting Planes for Bound-Propagation-Based Neural Network Verification. NeurIPS 2022.

[4] Wang, S., et al. (2021). Beta-CROWN: Efficient Bound Propagation with Per-neuron Split Constraints for Neural Network Robustness Verification. NeurIPS 2021 Workshop.

[5] VNN-COMP (2023–2024). International Verification of Neural Networks Competition. Website. Available at: https://sites.google.com/view/vnn2024 (Accessed: 5 April 2026).

[6] α,β-CROWN Developers. (n.d.). α,β-CROWN: A GPU-accelerated neural network verifier. GitHub repository. Available at:https://github.com/Verified-Intelligence/alpha-beta-CROWN (Accessed: 5 April 2026).

[7] Marabou Developers. (n.d.). Marabou: A framework for neural network verification. GitHub repository. Available at : https://github.com/NeuralNetworkVerification/Marabou (Accessed: 5 April 2026).